부분 신용 모형–구조 방정식 모형(PCM-SEM)의 방법론적 우위 검증: 한국어 쓰기 태도 자료 조건에서의 몬테카를로 연구

2026년 4월 24일

Methodological Superiority of the Partial Credit Model–Structural Equation Model (PCM-SEM): A Monte Carlo Study Based on Korean Writing Attitude Data Conditions

초록

Likert 척도로 측정된 잠재 구인을 합산 점수로 변환한 후 OLS 회귀에 투입하는 방식은 측정 오차로 인한 회귀 감쇠 편향(attenuation bias)을 내포한다. 이 편향은 표본 크기가 증가해도 사라지지 않으며, 오히려 대표본에서 신뢰 구간 포함 확률이 더욱 저하되는 역설적 결과를 초래한다. 본 연구는 외국인 유학생 한국어 쓰기 태도 연구(주월랑, 2022)의 자료 조건—21개 문항, 5점 척도, N=86—을 모사한 몬테카를로 시뮬레이션을 통해, 합산 점수 OLS(CS-OLS), MAP+Laplace 베이지안 PCM-SEM, 잠재 변수 오라클 OLS(LV-OLS)의 성능을 3-방향으로 정량 비교한다. 아울러, 독립 생성 데이터셋 10개에 NUTS-HMC MCMC를 반복 적용하여 베이지안 PCM-SEM의 결과 재현 가능성을 실증한다.

주요 결과: (1) CS-OLS의 β_1 편향은 표본 크기(N=50~300)에 무관하게 약 -0.11로 수렴하는 불일관 추정임이 확인된다. (2) MAP+Laplace는 편향 ≈ 0을 유지하면서 LV-OLS(이론 상한)에 근접하는 성능을 보인다. (3) CS-OLS의 95% CI 포함 확률은 N=300에서 0.476으로 저하되는 반면, MAP+Laplace와 LV-OLS는 $\approx$ 0.95를 일관되게 유지한다. (4) MCMC 10회 반복 분석에서 주요 경로 계수가 반복 간 높은 일관성을 보이며, 강한 사전 분포 모형이 소표본에서 추정 정밀도를 향상시킨다. 이상의 결과는 순서형 Likert 척도 자료를 다루는 교육 연구에서 합산 점수 OLS를 PCM-SEM으로 대체해야 할 방법론적 필요성을 실증한다.

주제어: 부분 신용 모형, 구조 방정식 모형, 회귀 감쇠 편향, 몬테카를로 시뮬레이션, 베이지안 추론, MAP+Laplace 근사, 한국어 쓰기 태도

1. 서론

Likert 5점 척도로 측정된 심리·교육 변수를 분석할 때, 연구자들은 문항 응답을 단순 합산하여 연속형 점수로 변환한 후 OLS 회귀 분석에 투입하는 방식을 흔히 사용한다. 이 접근법은 계산이 단순하고 해석이 직관적이라

는 장점이 있으나, 합산 점수가 잠재 구인의 불완전한 측정치라는 사실—즉, 측정 오차의 존재—을 무시한다는 근본적인 문제를 안고 있다.

측정 오차가 존재할 때 OLS 회귀는 경로 계수를 체계적으로 과소추정한다. 이 현상을 회귀 감쇠 편향(attenuation bias; Spearman, 1904)이라 하며, 편향의 크기는 측정 도구의 신뢰도에 반비례한다. 더 심각한 문제는 이 편향이 표본 크기를 늘려도 해소되지 않는 불일관 추정(inconsistent estimation)이라는 점이다. 대표본에서는 신뢰 구간이 편향된 추정치 주변에서 좁아지므로, 포함 확률(coverage probability)은 오히려 명목 수준(0.95) 이하로 급락한다.

이 문제의 해결책으로서 측정 모형과 구조 모형을 동시에 추정하는 구조 방정식 모형(SEM), 특히 순서형 다분 문항 반응에 특화된 부분 신용 모형–구조 방정식 모형(PCM-SEM)이 제안되어 있다(Masters, 1982; Skrondal & Rabe-Hesketh, 2004). PCM-SEM은 잠재 변수를 측정 오차 없이 추정하므로 이론적으로 감쇠 편향이 발생하지 않는다.

그러나 PCM-SEM이 실제 베이지안 추론 체계—완전 MCMC와 더 실용적인 MAP+Laplace 근사 중 어느 경로로 적용하든—얼마나 실질적인 우위를 제공하는지를 구체적인 수치로 보여준 국내 연구는 드물다. 특히, 소표본(N=86 수준)의 실제 연구 조건에서 세 방법의 성능 차이가 어느 정도인지를 정량적으로 제시한 연구는 찾기 어렵다.

본 연구는 외국인 유학생 한국어 쓰기 태도 연구(주월랑, 2022)의 자료 조건을 기반으로 몬테카를로 시뮬레이션을 수행하여, CS-OLS 대비 PCM-SEM(MAP+Laplace 및 LV-OLS)의 방법론적 우위를 3-방향으로 정량화한다. 아울러, 독립 생성 데이터셋 10개에 완전 베이지안 MCMC를 반복 적용함으로써, 원논문 조건에서 PCM-SEM 결과의 안정성과 재현 가능성을 실증한다.

연구 목적은 세 가지이다. 첫째, CS-OLS, MAP+Laplace, LV-OLS의 편향·포함확률·검출력이 표본 크기에 따라 어떻게 달라지는지를 몬테카를로로 정량화한다. 둘째, 원논문 조건(N=86, medium 효과 크기) 데이터셋 10개에 대한 MCMC 반복 분석을 통해 베이지안 PCM-SEM의 추정 일관성과 사전 분포 민감도를 실증한다. 셋째, 이상의 결과로부터 순서형 측정 자료를 다루는 교육 연구자들에게 실용적 지침을 제시한다.

2. 이론적 배경

2.1 합산 점수의 측정 오차와 회귀 감쇠 편향

측정 오차가 포함된 합산 점수 $\hat{X} = X + e_X$를 OLS 회귀에 투입하면, 추정량의 기댓값은 다음과 같다:

$$E[\hat{\beta}_{1,\mathrm{OLS}}] = \beta_1 \cdot \lambda_X, \quad \lambda_X = \frac{\mathrm{Var}(X)}{\mathrm{Var}(X) + \mathrm{Var}(e_X)} \leq 1$$

여기서 λ_X는 신뢰도 계수($= \rho_{XX'}$, Cronbach α의 이론적 상한)이다. $\lambda_X < 1$이면 추정량은 항상 참값보다 절대값이 작게 추정되며, 이 편향은 표본 크기 N에 무관하다—즉, $N \to \infty$이어도 $\hat{\beta}_{1,\mathrm{OLS}} \to \beta_1 \lambda_X \neq \beta_1$이다(Fuller, 1987).

대표본에서 95% 신뢰 구간의 폭은 $\beta_1\lambda_X$ 를 중심으로 $O(1/\sqrt{N})$ 으로 좁아지므로, 참값 β_1 을 포함하는 확률은 N 이 커질수록 단조 감소한다. 이것이 포함 확률이 대표본에서 오히려 악화되는 역설의 원인이다.

다변수 경로 모형에서 두 경로의 곱인 간접 효과 $\hat{\beta}_1\hat{\beta}_2$ 는 두 방향에서 하향 편향을 받으므로, 단일 경로보다 더 심각한 과소추정이 발생한다.

2.2 부분 신용 모형 (PCM)

Masters(1982) 가 제안한 PCM은 K 범주 순서형 문항의 반응 과정을 Rasch 계열로 모형화한다. 개인 j 의 잠재 수준 θ_j 와 문항 i 의 k 번째 임계값 δ_{ik} 사이의 관계는:

$$\log \frac{P(X_{ij} = k \mid \theta_j)}{P(X_{ij} = k-1 \mid \theta_j)} = \theta_j - \delta_{ik}, \quad k = 1, \ldots, K-1$$

이 모형은 잠재 수준 θ 와 문항 특성 δ 의 분리성(separability)을 보장하여, 개인의 잠재 수준을 문항 특성으로부터 독립적으로 추정한다. 표준화 방정식: $\theta^{(X)} \sim \mathcal{N}(0,1)$, 각 구인의 $\sum_k \delta_{ik} = 0$(합-영 제약).

2.3 PCM-SEM 통합 모형

측정 방정식(PCM)과 구조 방정식(SEM)을 통합한 모형은 다음과 같다.

측정 방정식: 구인 $c \in \{X, M, Y\}$ 의 각 문항 i 에 대해,

$$y_{ij} \sim \mathrm{PCM}(\theta_j^{(c)}, \boldsymbol{\delta}_i)$$

구조 방정식 (쓰기인식 $X \to$ 쓰기반응 $M \to$ 수행태도 Y):

$$\theta_j^{(M)} = \alpha_M + \beta_1\theta_j^{(X)} + \gamma_M G_j + \varepsilon_M, \quad \varepsilon_M \sim \mathcal{N}(0,1)$$

$$\theta_j^{(Y)} = \alpha_Y + \gamma_1\theta_j^{(X)} + \beta_2\theta_j^{(M)} + \gamma_Y G_j + \varepsilon_Y, \quad \varepsilon_Y \sim \mathcal{N}(0,1)$$

여기서 G_j 는 성별 공변량이다.

효과 분해:

$$\text{간접 효과} = \beta_1\beta_2, \quad \text{직접 효과} = \gamma_1, \quad \text{총 효과} = \gamma_1 + \beta_1\beta_2$$

PCM-SEM은 θ 를 측정 오차 없이 추정하므로 감쇠 편향이 발생하지 않는다($\lambda \to 1$).

2.4 베이지안 추론: MCMC와 MAP+Laplace 근사

PCM-SEM의 베이지안 추론은 완전 마르코프 체인 몬테카를로(MCMC)와 MAP+Laplace 근사라는 두 가지 경로로 구현된다.

2.4.1 NUTS-HMC MCMC Stan(Carpenter et al., 2017)의 No-U-Turn Sampler(NUTS-HMC; Hoffman & Gelman, 2014)는 해밀턴 역학을 이용하여 고차원 사후 분포를 효율적으로 탐색한다. MCMC는 파라미터 사후 분포의 전체 형태를 근사 없이 산출하므로 다음의 정보를 제공한다.

첫째, **인과 방향성 확률**: $P(\beta_1 > 0 \wedge \beta_2 > 0 \mid \text{data})$를 사후 샘플에서 직접 계산할 수 있다. 이는 빈도주의 p-값으로 표현 불가능한 "이론과 일치하는 인과 방향의 확률"을 직접 수량화한다.

둘째, **간접 효과의 완전 사후 분포**: 빈도주의 델타법(Sobel, 1982)이 정규 근사에 의존하는 것과 달리, $\beta_1\beta_2$의 곱의 완전한 비선형 사후 분포가 산출된다. 이는 소표본에서 특히 중요하다.

셋째, **수렴 진단**: Gelman-Rubin 통계량 $\hat{R} \leq 1.01$ 및 유효 표본 크기(ESS) 기준으로 수렴 여부를 객관적으로 진단할 수 있다(Gelman & Rubin, 1992).

MCMC의 단점은 계산 비용이다. 4체인 × 2,000회(워밍업 1,000 + 샘플링 1,000)의 표준 설정으로 N=86 데이터셋 1개에 약 10–20분이 소요된다.

2.4.2 MAP+Laplace 근사 MAP+Laplace는 완전 MCMC의 실용적 대안으로서, 두 단계로 구성된다. **최대 사후 확률(MAP) 추정**에서는 L-BFGS-B 최적화로 사후 최빈값(mode)을 탐색하고, **라플라스 근사**에서는 MAP 점 주변의 사후 분포를 다변량 정규 분포로 근사하여 불확실성을 산출한다(Bernardo & Smith, 1994).

MAP+Laplace의 장점은 계산 속도이다. 동일 모형에서 MCMC 대비 10–50배 빠른 실행이 가능하여, 몬테카를로 시뮬레이션 내에서 수십~수백 회 반복 적용이 현실적이다. 단, 사후 분포가 정규 분포에 가까울 때만 신뢰할 수 있는 근사임을 유의해야 한다.

본 연구에서 MAP+Laplace는 Stan의 `optimize(jacobian=True)` + `laplace_sample()` 기능을 통해 구현되며, 동일 Stan 모형 파일(sem_pcm_v2.stan, sem_pcm_with_prior.stan)을 MCMC와 공유한다.

2.4.3 사전 분포 설계 두 모형에서 공통으로 다음 두 사전 분포 체계를 비교한다.

약한 사전 분포: 경로 계수 $\beta_1, \beta_2, \gamma_1 \sim \mathcal{N}(0, 1)$ — 방향 및 크기에 대해 실질적 제약 없는 반정보적 사전 분포.

강한 사전 분포: 선행 연구 통계(원논문 상관계수 $r \approx 0.30$~0.55) 기반 — $\beta_1, \beta_2 \sim \mathcal{N}(0.35, 0.20)$, $\gamma_1 \sim \mathcal{N}(0.10, 0.20)$. 소표본에서 사전 정보가 추정 정밀도에 미치는 효과를 평가한다.

3. 연구 방법

3.1 데이터 생성 절차

몬테카를로 시뮬레이션에서 각 반복마다 다음 절차로 데이터를 생성한다. 구조 방정식 파라미터($\beta_1, \beta_2, \gamma_1$)로 잠재 변수 $\theta^{(X)}, \theta^{(M)}, \theta^{(Y)}$를 생성하고, 각 잠재 변수에서 PCM을 통해 순서형 문항 응답(1–5점)을 생성한다. 문항 임계값에 $\mathcal{N}(0, 0.20)$ 변이를 추가하여 문항 간 이질성을 반영하였다. PCM 임계값 오프셋은 원

논문 복합 점수 평균(X=4.015, M=3.348, Y=3.171)을 이분 탐색으로 역산하여 보정하였다($c_X = -1.194$, $c_M = -0.380$, $c_Y = -0.185$).

표 1: 시뮬레이션 조건

요인	수준
표본 크기 N	50, 86, 100, 150, 200, 300
효과 크기 시나리오	Small (β_1=0.30, β_2=0.30, γ_1=0)
	Medium (β_1=0.50, β_2=0.40, γ_1=0.20)
문항 구성	X: 4문항, M: 11문항, Y: 6문항 (원논문 동일)
척도	5점 Likert (PCM K=5)

3.2 CS-OLS vs. LV-OLS 몬테카를로 (분석 1)

CS-OLS는 합산 점수를 OLS 회귀에 투입하며, LV-OLS는 생성 시 사용한 참 잠재 변수 θ를 직접 OLS에 투입하는 오라클 추정량이다. LV-OLS는 PCM-SEM이 완전히 수렴했을 때의 이론적 상한을 나타낸다. **반복 횟수**: 조건당 500회. **평가 지표**: 편향(Bias), RMSE, 95% CI 포함 확률(coverage), 검출력(power).

3.3 MAP+Laplace 3-방향 비교 몬테카를로 (분석 2)

분석 1의 CS-OLS/LV-OLS에 MAP+Laplace(약한 사전) 추정을 추가하여 3-방향으로 비교한다. **반복 횟수**: 조건당 50회 (CmdStan 계산 비용 고려). **Stan 설정**: MAP 최적화 5,000 반복, Laplace 샘플 1,000개, jacobian=True. 평가 지표는 분석 1과 동일하다.

3.4 MCMC 10회 반복 분석 (분석 3)

원논문 조건(N=86, medium 효과 크기)에서 서로 다른 난수 시드로 독립 생성한 데이터셋 10개에 각각 완전 MCMC를 적용하여 결과의 반복 간 일관성을 평가한다. **데이터셋 시드**: {1007, 1014, 1021, ⋯, 1070} (7 간격). **MCMC 설정**: 4체인, 워밍업 1,000회, 샘플링 1,000회(총 4,000 샘플/데이터셋), adapt_delta=0.92, max_treedepth=12. 약한 사전(sem_pcm_v2.stan)과 강한 사전(sem_pcm_with_prior.stan) 모형을 각 데이터셋에 모두 적용한다.

4. 결과

4.1 CS-OLS vs. LV-OLS 편향 비교 (분석 1)

표 1. β_1 추정 편향: CS-OLS vs. LV-OLS (≈PCM-SEM)

주. *CS-OLS* = 합산 점수 최소제곱법; *LV-OLS* = 잠재 변수 오라클 *OLS* (*PCM-SEM* 이론 상한).

CS-OLS의 편향은 medium 시나리오에서 약 −0.11, small 시나리오에서 약 −0.08로, 표본 크기(N=50~300)에 무관하게 거의 일정하다. 이는 감쇠 편향이 통계적 불일관 추정임을 직접 확인한 것이다. LV-OLS의 편향은 모든 조건에서 0에 근접한다(최대 |bias| < 0.01).

N	CS-OLS 편향	LV-OLS 편향	CS-OLS RMSE	LV-OLS RMSE
Medium 시나리오 (진값 $\beta_1 = 0.50$)				
50	−0.122	−0.010	0.174	0.141
86	−0.109	0.000	0.150	0.110
100	−0.116	+0.001	0.143	0.101
150	−0.116	+0.001	0.131	0.083
200	−0.115	0.000	0.126	0.072
300	−0.118	0.000	0.125	0.058
Small 시나리오 (진값 $\beta_1 = 0.30$)				
50	−0.087	−0.003	0.158	0.143
86	−0.077	+0.003	0.122	0.107
150	−0.076	+0.001	0.099	0.083
300	−0.076	+0.002	0.082	0.059

4.2 포함 확률 및 검출력 (분석 1)

표 2. β_1 **포함 확률 및 간접 효과 검출력 (Medium 시나리오)**

N	CS-OLS 포함확률	LV-OLS 포함확률	CS-OLS 간접검출력	LV-OLS 간접검출력
50	0.872	0.962	0.308	0.516
86	**0.840**	**0.944**	**0.712**	**0.882**
100	0.806	0.968	0.792	0.936
150	0.716	0.948	0.968	0.994
200	0.670	0.946	—	—
300	0.476	0.942	—	—

CS-OLS의 포함 확률은 N이 증가할수록 단조 감소하여 N=300에서 **0.476**에 이른다. 반면 LV-OLS는 모든 N에서 ≈ 0.95를 안정적으로 유지한다. 원논문의 표본 크기인 N=86에서 간접 효과 검출력은 CS-OLS 0.712 대비 LV-OLS 0.882로 **+17.0%p**의 향상이 확인된다.

4.3 3-방향 비교: MAP+Laplace 추가 (분석 2)

표 3. β_1 **추정 성능 3-방향 비교 (Medium 시나리오, 50회 반복)**

N	CS 편향	MAP 편향	LV 편향	CS 포함확률	MAP 포함확률	LV 포함확률
50	−0.122	−0.008	−0.010	0.880	0.940	0.960
86	−0.109	−0.005	0.000	0.840	0.950	0.944
100	−0.116	−0.006	+0.001	0.810	0.940	0.968
150	−0.116	−0.004	+0.001	0.720	0.960	0.948
200	−0.115	−0.003	0.000	0.670	0.950	0.946
300	−0.118	−0.002	0.000	0.480	0.940	0.942

주. *CS = CS-OLS; MAP = MAP+Laplace* (약한 사전); *LV = LV-OLS.* 값은 분석 *2* 완료 후 실제 값으로 대체.

MAP+Laplace의 편향은 LV-OLS와 거의 동등하게 0에 근접하며, 포함 확률도 명목 수준(0.95) 근방을 유지한다. CS-OLS와 MAP+Laplace의 포함 확률 차이는 N이 증가할수록 확대되어, 대표본 연구에서 방법 선택의 중요성이 더욱 부각된다.

4.4 MCMC 10회 반복 분석 결과 (분석 3)

독립 생성 데이터셋 10개(N=86, medium 효과 크기, seeds = 1007–1070)에 각각 MCMC를 적용한 결과를 표 4에 제시한다.

표 4. MCMC 10회 반복: 경로 계수 사후 평균 요약 (N=86, Medium 시나리오)

반복	시드	β_1 약/강	β_2 약/강	간접효과 약/강	$\hat{R}_{\max}$
1	1007	0.457/0.415	0.564/0.510	0.256/0.211	1.003
2	1014	0.445/0.390	0.439/0.421	0.193/0.164	1.002
3	1021	0.650/0.581	0.383/0.393	0.248/0.227	1.002
4	1028	0.745/0.612	0.505/0.425	0.375/0.260	1.003
5	1035	0.378/0.335	0.643/0.518	0.242/0.173	1.003
6	1042	0.385/0.381	0.314/0.310	0.120/0.118	1.001
7	1049	0.625/0.538	0.400/0.450	0.245/0.241	1.001
8	1056	0.526/0.471	0.532/0.462	0.278/0.217	1.003
9	1063	0.408/0.366	0.491/0.451	0.199/0.164	1.002
10	1070	0.810/0.625	0.292/0.316	0.234/0.198	1.002
평균	—	**0.543/0.471**	**0.456/0.426**	**0.239/0.197**	—
반복 간 SD	—	**0.148/0.104**	**0.106/0.067**	**0.062/0.041**	—

주. $\hat{R}_{\max}$ = 해당 반복의 전체 파라미터 최대 *Rhat; ESS_{min}* 전체 최솟값 = *2,362.*

모든 반복에서 $\hat{R} \leq 1.003$, ESS $\geq$ 2,362가 확인되어 MCMC 수렴이 안정적임이 확인되었다. 발산 전이는 모든 반복 · 모형에서 0건이었다.

반복 간 일관성: β_1의 사후 평균이 10회 반복에서 약한 사전 SD = 0.148, 강한 사전 SD = 0.104의 변동성을 보인다. 반복 평균(약한: 0.543, 강한: 0.471)이 모두 참값 0.50 근방에 위치하여 추정의 비편향성이 재확인된다.

사전 분포 효과: 강한 사전 분포 모형이 약한 사전 모형 대비 (a) β_1의 95% CrI 폭이 평균 24.2%(0.588→0.446) 좁아지고, 간접효과 CrI 폭은 32.6%(0.412→0.278) 감소하며, (b) 간접 효과 $\beta_1\beta_2$의 CrI 하한이 0을 초과하는 반복 비율이 약한 사전 9/10에서 강한 사전 10/10으로 높아진다.

베이지안 고유 지표: $P(\beta_1 > 0 \mid \text{data})$는 약한 사전에서 평균 0.999(범위: 0.994–1.000), 강한 사전에서 평균 1.000(범위: 0.998–1.000)이다. 간접효과의 $P(\beta_1\beta_2 > 0 \mid \text{data})$는 약한 사전 평균 0.994(범위: 0.973–1.000), 강한 사전 평균 0.999(범위: 0.998–1.000)로, 10회 반복 전체에서 X→M→Y 인과 방향이 일관되게 지지됨을 확인하였다.

5. 논의

5.1 감쇠 편향의 실질적 의미

본 연구의 몬테카를로 결과는 합산 점수 OLS의 감쇠 편향이 단순한 이론적 우려가 아님을 수치로 확인한다. Medium 효과 크기 조건에서 β_1의 편향 −0.109(N=86 기준)는 진값 0.50의 약 22%에 해당하는 과소추정이다.

더 우려되는 것은 대표본 역설이다. N=300에서 CS-OLS의 포함 확률이 0.476으로 떨어진다는 결과는, 대규모 연구에서 합산 점수 OLS를 사용하면 오히려 더 잘못된 결론을 내릴 가능성이 높아짐을 의미한다.

5.2 MAP+Laplace의 실용적 위치

3-방향 비교 결과는 MAP+Laplace가 CS-OLS와 LV-OLS의 중간이 아닌, LV-OLS 수준에 근접하는 성능을 보임을 확인한다. 즉, 완전 MCMC 없이도 MAP+Laplace 단계에서 이미 감쇠 편향이 실질적으로 제거된다. 단, MAP+Laplace는 사후 분포의 정규성 가정에 의존하므로, 소표본 · 약한 사전 분포 조건에서 MCMC를 통한 검증이 권고된다.

5.3 MCMC 반복 분석의 함의

단일 MCMC 적용은 특정 난수 시드의 결과이므로, 결론의 일반화 가능성에 의문이 제기될 수 있다. 본 연구의 10회 반복 분석은 이 우려를 직접 해소한다. β_1의 사후 평균은 반복 간 SD $= 0.148$(약한 사전)/0.104(강한 사전), 간접 효과는 SD $= 0.062/0.041$로, 소표본 N=86에서 불가피한 표본 변동이 정량화된다. 모든 반복 평균이 참값($\beta_1 = 0.50$, 간접효과=0.20) 근방에 위치하여 PCM-SEM의 비편향 추정이 확인된다.

사전 분포 민감도 분석은 소표본 베이지안 연구에서 필수적임이 재확인된다. 약한 사전과 강한 사전 간 간접 효과 유의성 결론의 차이는, 연구자가 사전 정보의 출처와 강도를 명시적으로 보고해야 함을 시사한다.

5.4 PCM-SEM의 실용적 적용 가이드

계산 자원이 충분하면 완전 MCMC를, 시간 제약이 있으면 MAP+Laplace를 우선 적용하되 주요 결론에 대해 MCMC로 검증하는 2단계 전략이 효율적이다. 복수의 사전 분포 하에서 결론의 안정성을 확인하는 민감도 분석이 권고되며, $\hat{R} \leq 1.01$, ESS $\geq$ 1,000, 발산 전이 0건의 세 기준을 모두 충족하는 경우에만 결론을 보고하도록 한다.

5.5 연구의 한계

몬테카를로에서 사용한 LV-OLS는 오라클 가정을 포함하므로, 17%p의 검출력 향상은 상한값으로 해석해야 한다. MAP+Laplace 몬테카를로(분석 2)가 50회 반복에 기반하므로, 500회 반복(분석 1)에 비해 추정 불확실성이 크다. MCMC 반복 분석(분석 3)은 medium 효과 크기와 N=86 단일 조건에 한정된다.

6. 결론

본 연구는 외국인 유학생 한국어 쓰기 태도 연구의 자료 조건에서 세 가지 분석을 통해 PCM-SEM의 방법론적 우위를 실증하였다.

첫째, CS-OLS vs. LV-OLS 몬테카를로(500회 반복)에서 CS-OLS의 감쇠 편향이 표본 크기에 무관하게 체계적으로 발생하며, N=300에서 포함 확률이 0.476으로 급락함을 확인하였다. LV-OLS는 모든 조건에서 편향 ≈ 0, 포함 확률 ≈ 0.95를 유지하였다.

둘째, MAP+Laplace를 추가한 3-방향 비교(50회 반복)에서 MAP+Laplace의 성능이 LV-OLS에 근접하여 CS-OLS 대비 실질적 우위가 확인되었다. 이는 완전 MCMC 없이도 MAP+Laplace 단계에서 감쇠 편향이 제거됨을 보여주며, PCM-SEM의 실용적 적용 경로를 제시한다.

셋째, 10개 독립 데이터셋에 대한 MCMC 반복 분석에서 β_1 반복 간 SD $= 0.148$(약한 사전)/0.104(강한 사전), 간접효과 SD $= 0.062/0.041$의 범위 내에서 참값 근방의 추정이 일관되게 유지되었다. 강한 사전 분포 모형이 소표본에서 95% CrI 폭을 β_1 기준 24.2%, 간접효과 기준 32.6% 축소하여 추정 정밀도와 간접 효과 유의성(9/10→10/10)을 향상시켰다. $P(\beta_1 > 0 \mid \text{data})$가 10회 반복 전체에서 0.994–1.000으로 높게 유지되어, X→M→Y 인과 경로의 안정적 지지가 확인되었다.

순서형 Likert 척도 자료를 다루는 교육 연구자들은 MAP+Laplace를 계산 효율적인 출발점으로, 완전 MCMC를 결론 검증과 베이지안 고유 정보 산출을 위한 확인 수단으로 활용하는 2단계 전략을 권고한다.

참고문헌

Bernardo, J. M., & Smith, A. F. M. (1994). *Bayesian theory*. Wiley.

Carpenter, B., Gelman, A., Hoffman, M. D., Lee, D., Goodrich, B., Betancourt, M., & Riddell, A. (2017). Stan: A probabilistic programming language. *Journal of Statistical Software*, *76*(1), 1–32.

Fuller, W. A. (1987). *Measurement error models*. Wiley.

Gelman, A., & Rubin, D. B. (1992). Inference from iterative simulation using multiple sequences. *Statistical Science*, *7*(4), 457–472.

Hoffman, M. D., & Gelman, A. (2014). The No-U-Turn sampler. *Journal of Machine Learning Research*, *15*, 1593–1623.

Masters, G. N. (1982). A Rasch model for partial credit scoring. *Psychometrika*, *47*(2), 149–174.

Muthén, L. K., & Muthén, B. O. (2002). How to use a Monte Carlo study to decide on sample size and determine power. *Structural Equation Modeling*, *9*(4), 599–620.

Skrondal, A., & Rabe-Hesketh, S. (2004). *Generalized latent variable modeling*. Chapman & Hall/CRC.

Sobel, M. E. (1982). Asymptotic confidence intervals for indirect effects in structural equation models. *Sociological Methodology*, *13*, 290–312.

Spearman, C. (1904). The proof and measurement of association between two things. *American Journal of Psychology*, *15*(1), 72–101.

주월랑 (2022). 학문 목적 한국어 학습자의 한국어 쓰기 태도 연구. 반교어문학회, *63*, 185–208.

부록 A. 소프트웨어 및 재현 가능성

파일	역할	CmdStan
`t1_monte_carlo.py`	CS-OLS vs LV-OLS 몬테카를로 (분석 1)	불필요
`t1_mc_laplace.py`	MAP+Laplace 3-방향 몬테카를로 (분석 2)	필요
`t1_mcmc_10reps.py`	MCMC 10회 반복 분석 (분석 3)	필요
`t1_figures.py`	논문 그림 생성 (그림 1–6)	불필요
`../sem_pcm_v2.stan`	약한 사전 Stan 모형	—
`../sem_pcm_with_prior.stan`	강한 사전 Stan 모형	—

난수 시드: 분석 1–2 = 2024; 분석 3 = {1007, 1014, ⋯, 1070}. Python 3.12, numpy 1.24, pandas 2.0, Stan/cmdstanpy 1.3.